

Nom : NAVARRO

Prénom : Robin

Groupe : 5

### Exercice 1 : Descente de gradient

Pour rappel, la méthode de descente du gradient consiste à rechercher le minimum d'une fonction en se basant sur le signe de sa dérivée.

Soit une fonction  $f(x)$  et  $f'(x)$  sa dérivée par rapport à  $x$ . La technique de descente du gradient nous dit qu'un minimum de la fonction peut être trouvé en suivant l'algorithme suivant, étant donné un point de départ  $x_{init}$  et un pas d'apprentissage  $nu$ . Le critère d'arrêt dépend d'une valeur  $\epsilon$ .

$$x_{current} = x_{init} - nu \times f'(x_{init})$$

$$\text{distance} = |x_{current} - x_{init}|$$

Tant que ( $\text{distance} > \epsilon$ )

$$x_{init} = x_{current}$$

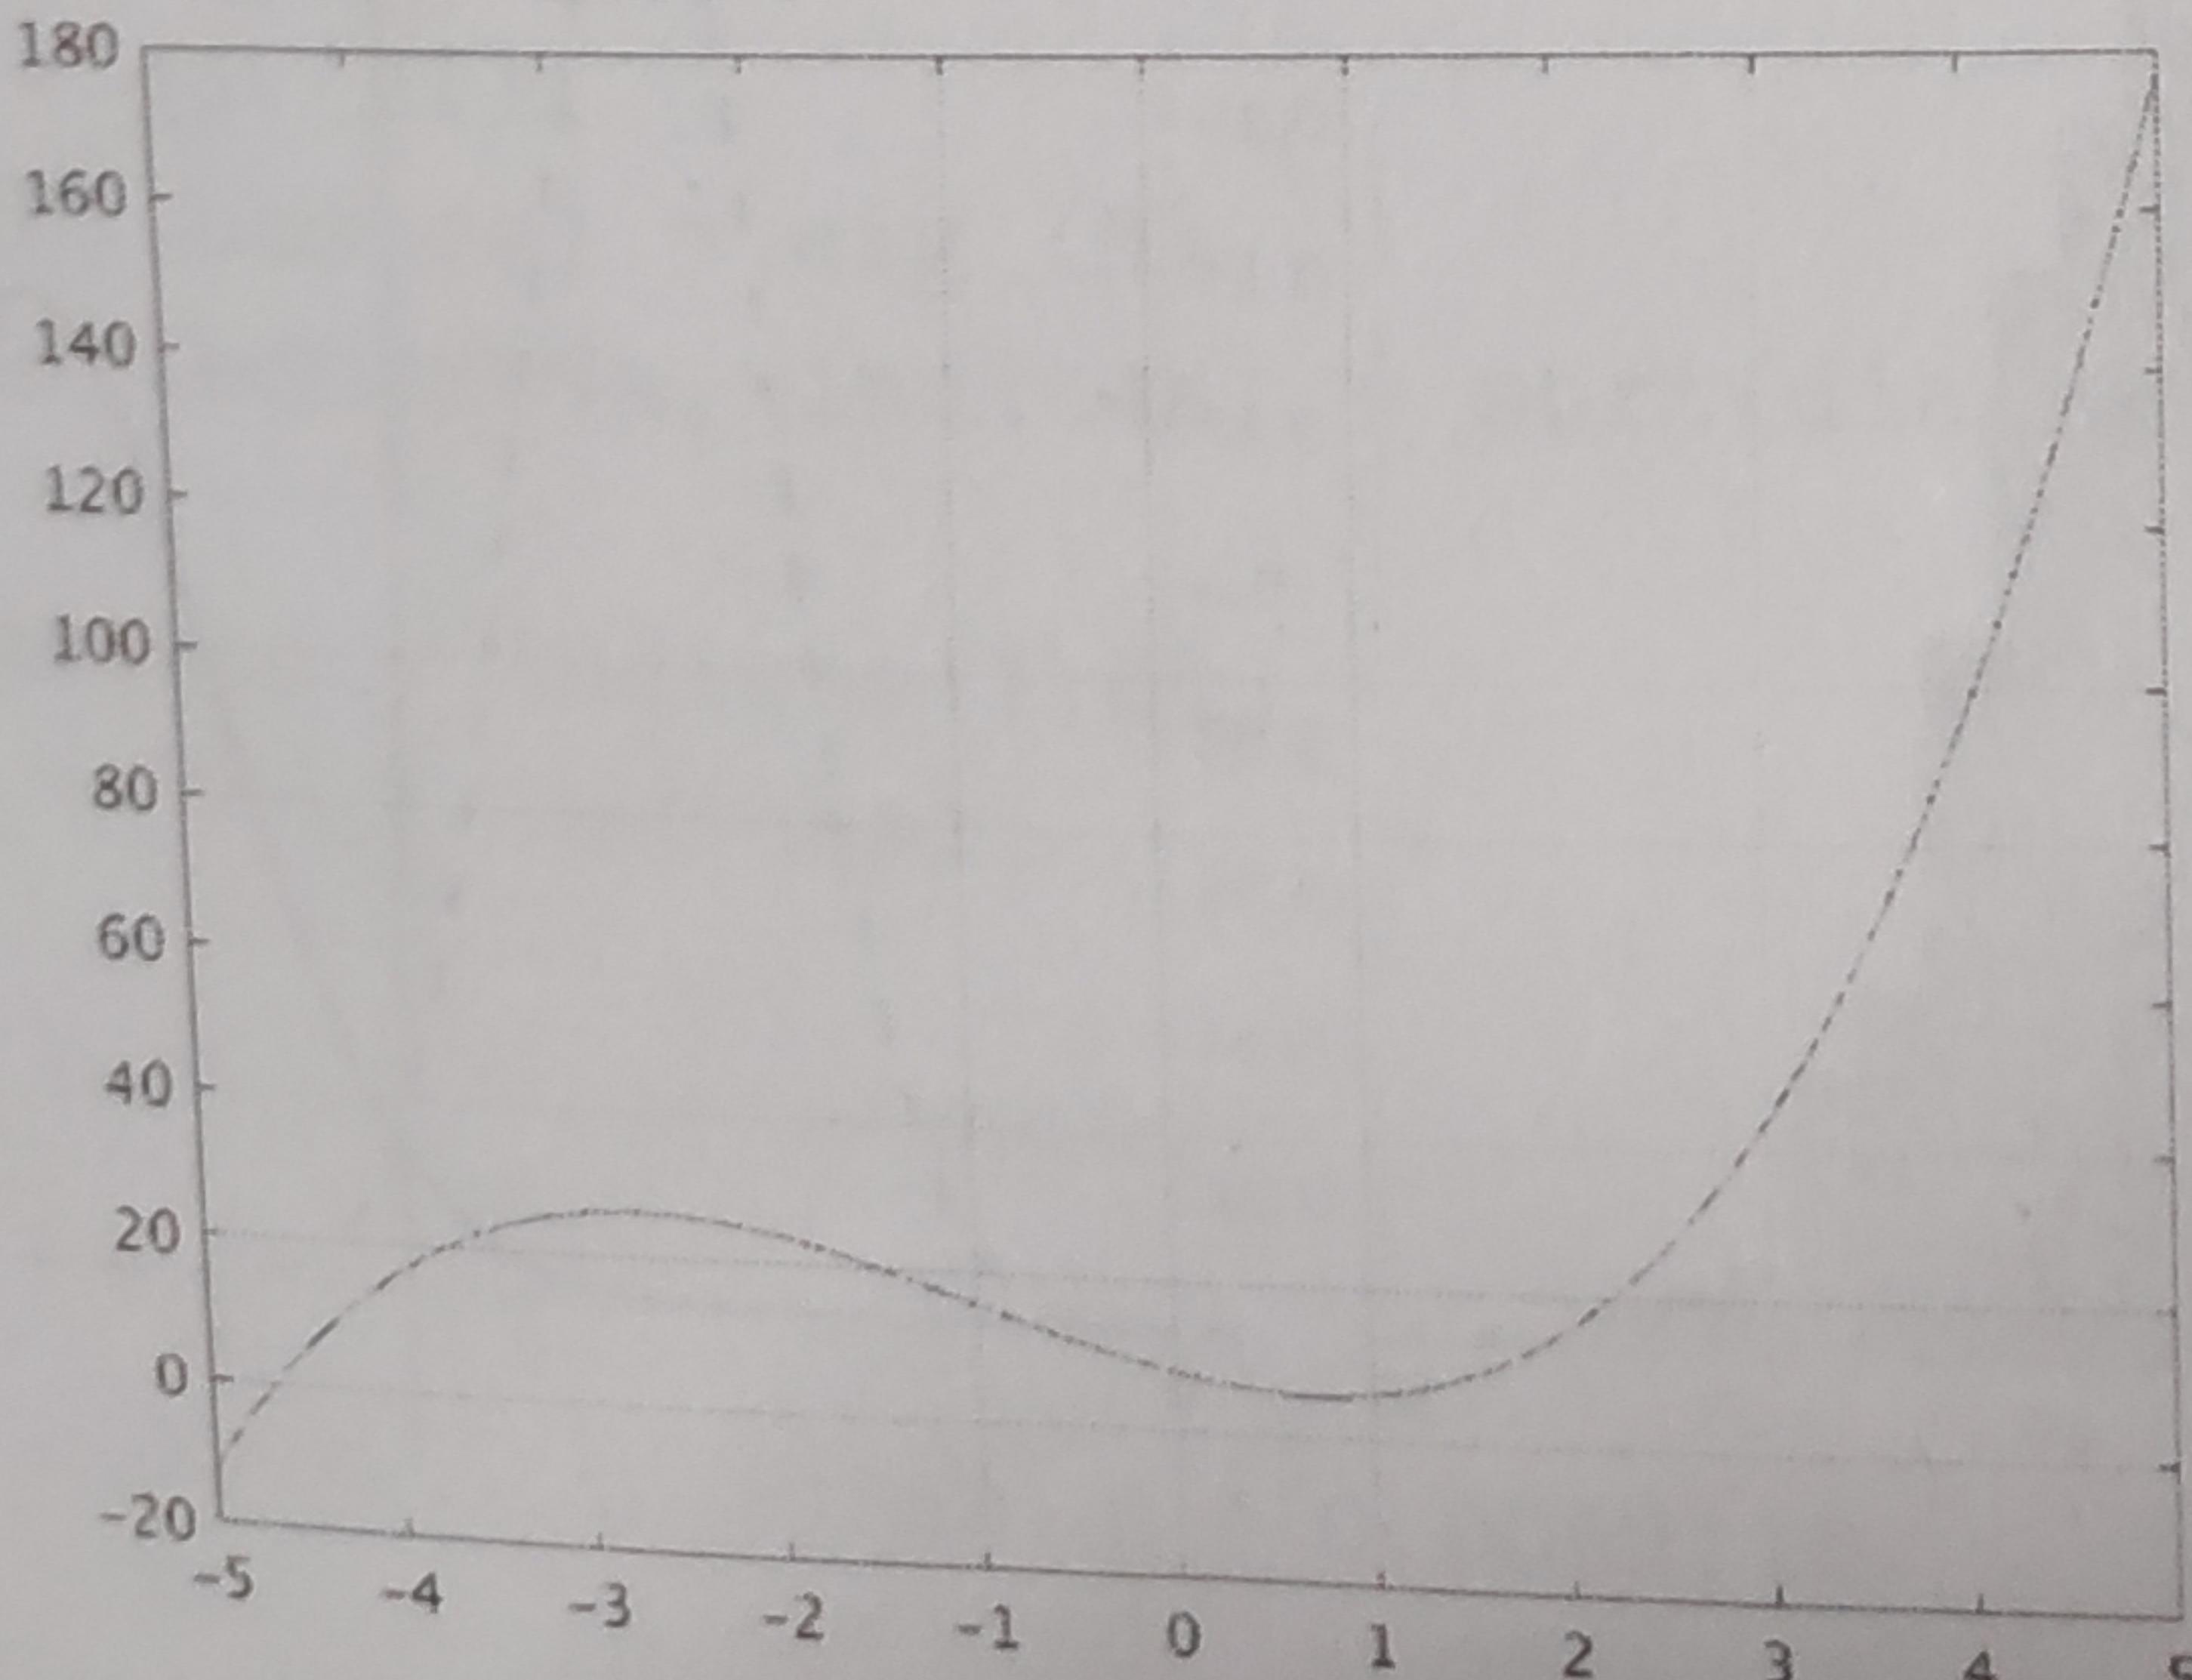
$$x_{current} = x_{init} - nu \times f'(x_{init})$$

$$\text{distance} = |x_{current} - x_{init}|$$

1. Expliquez l'algorithme en répondant aux questions suivantes :

- (a) Où intervient le signe de la dérivée ?
- (b) Quelle variable contient la position du minimum après exécution de l'algorithme ? Quelle est la valeur du minimum ?
- (c) Quelle est l'influence du paramètre  $\epsilon$  ?
- (d) Pourquoi faut-il introduire un pas d'apprentissage ( $nu$  dans l'algorithme) ? Que peut-il se passer si  $nu$  est trop petit ? S'il est trop grand ?

2. On étudie la fonction  $f(x) = x^3 + 3x^2 - 6x + 8$  dont la représentation graphique pour  $-5 \leq x \leq 5$  est la suivante :



- (a) Calculez sa dérivée  $f'(x)$ .

- (b) En prenant comme point de départ  $x_{init} = -1$ , comme pas d'apprentissage  $nu = 0.1$ , et en fixant  $\epsilon = 0.1$ , calculez les valeurs de  $x_{current}$  jusqu'à l'arrêt de l'algorithme.
- (c) Obtient-on le même résultat si on choisit  $x_{init} = 4$ ? Si on choisit  $x_{init} = -4$ ? Justifiez votre réponse sans faire de nouveaux calculs.

### Exercice 2 : Classifieur Bayésien (2 classes)

- Expliquez le principe des deux classificateurs vus en TD : classificateur bayésien basé sur le maximum de vraisemblance (ML) et classificateur bayésien basé sur le maximum a posteriori (MAP).

Vous noterez :

$p(C)$  la probabilité a priori de la classe  $C$ ,

$p(x|C)$  la probabilité qu'un individu ait  $x$  pour descripteur sachant qu'il appartient à la classe  $C$ ,

$p(C|x)$  la probabilité qu'un individu soit de classe  $C$  sachant qu'il a  $x$  comme descripteur.

Dans la suite, on fait l'hypothèse que les distributions de probabilités sont gaussiennes.

#### 2. Cas pratique A

On fournit les résultats du code Matlab suivant pour des données contenues dans les vecteurs  $Train1$  et  $Train2$ . Le vecteur  $Train1$  contient les exemples de la classe 1, le vecteur  $Train2$  contient les exemples de la classe 2.

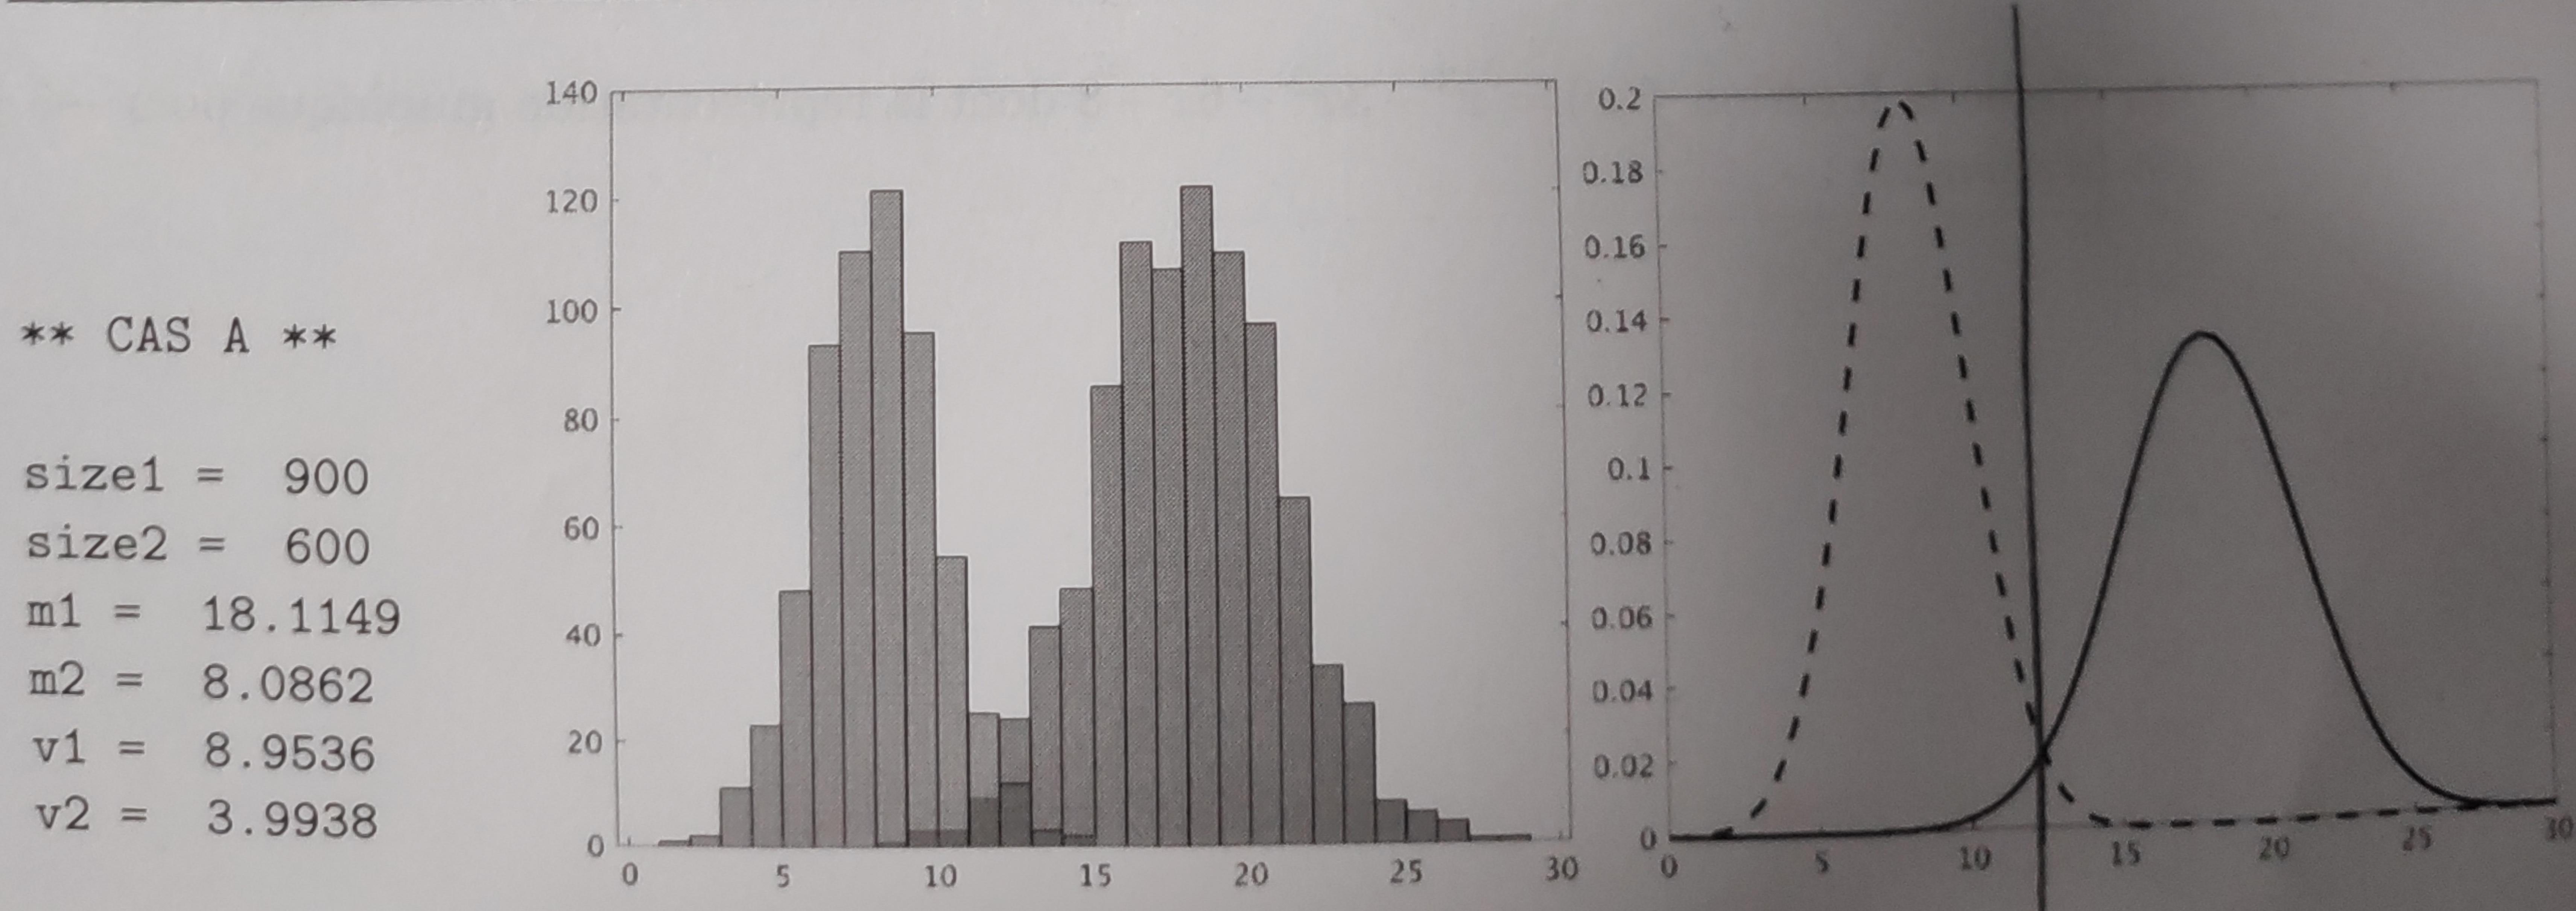
---

```

size1 = length(Train1)
size2 = length(Train2)
m1 = mean(Train1)
m2 = mean(Train2)
v1 = var(Train1)
v2 = var(Train2)
figure(1)
histogram(Train1);
hold on
histogram(Train2);
figure(2)
x = 0:0.5:30;
plot(x, normpdf(x, m1, sqrt(v1)), '-');
hold on
plot(x, normpdf(x, m2, sqrt(v2)), '--');

```

---



- Donnez les probabilités des classes 1 et 2.
- Donner une valeur approximative du seuil  $x_{seuil}$  de décision pour le classificateur ML (utilisez le sujet pour le construire géométriquement).

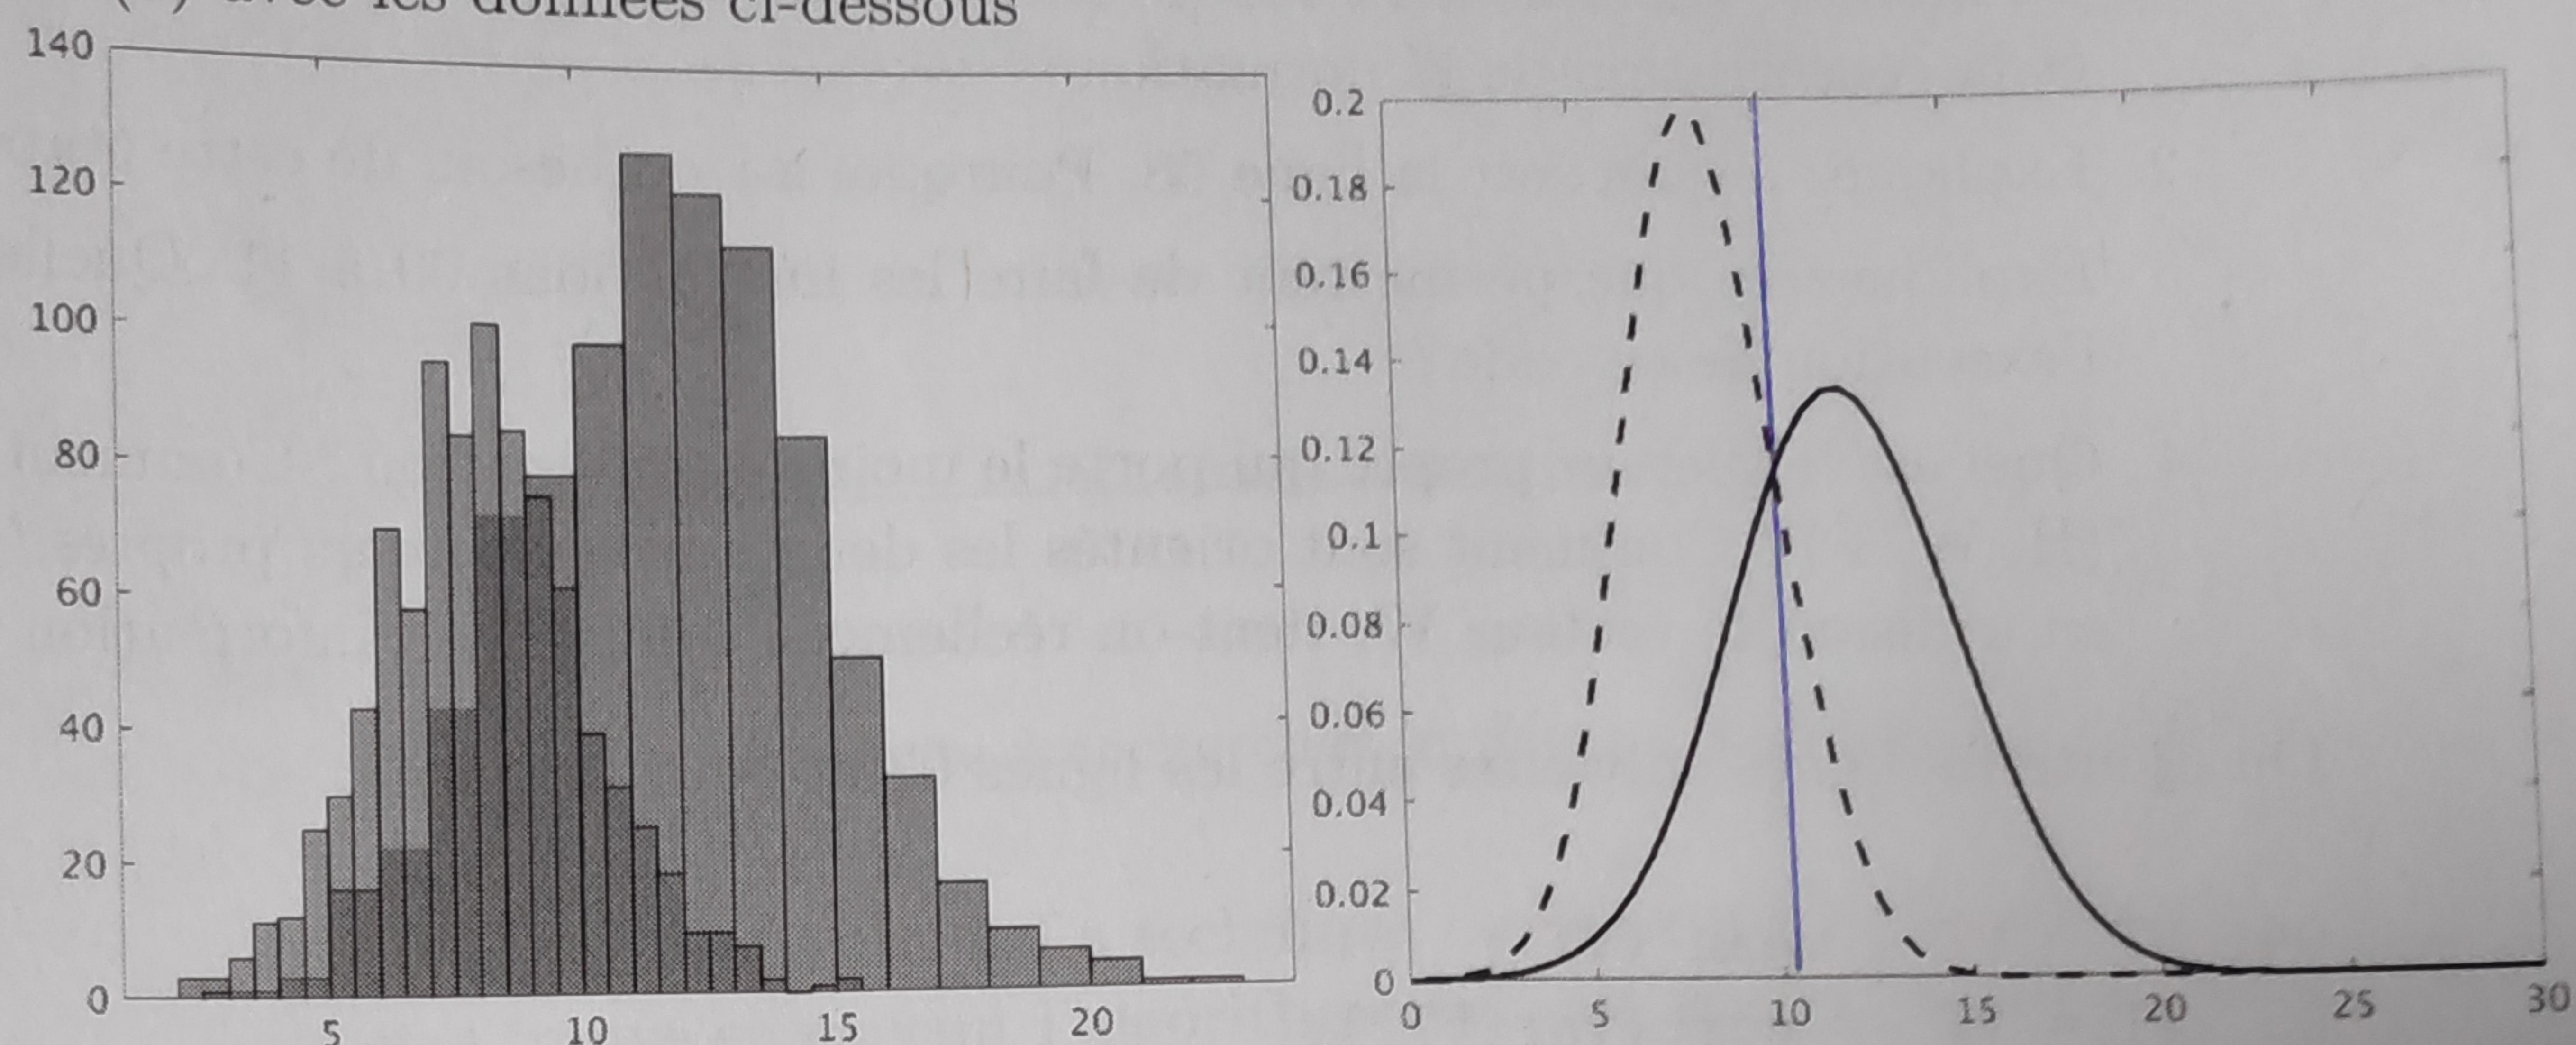
- (c) Le seuil de décision pour le classifieur MAP sera-t-il supérieur ou inférieur à  $x_{seuil}$ ? Expliquez.  
 (d) Au vu des informations fournies, pouvez-vous prévoir la qualité des résultats des classificateurs ML et MAP entraînés avec ces données? Expliquez.

### 3. Cas pratique B

Mêmes questions qu'au (2) avec les données ci-dessous

**\*\* CAS B \*\***

```
size1 = 900
size2 = 900
m1 = 11.8488
m2 = 8.0958
v1 = 8.9255
v2 = 4.0485
```



### Exercice 3 : Réduction en dimension

La table suivante contient des données relatives à un échantillon de femmes et d'hommes. Il s'agit de mesures relatives à la taille en mètre de la personne, à son poids en kg et à la longueur de ses pieds en cm.

S(ex)	H(eight) (m)	W(eight) (kg)	F(oot) size (cm)
M	1.82	82	30
M	1.80	86	28
M	1.70	77	30
M	1.80	75	25
F	1.52	45	15
F	1.65	68	20
F	1.68	59	18
F	1.75	68	23

On veut réduire ces informations de façon à obtenir une seule valeur par personne. Pour cela on veut utiliser l'ACP. Soit le code Matlab suivant :

```
01. H = [ 1.82, 82, 30; 1.80, 86, 28; 1.70, 77, 30; 1.80, 75, 25];
02. F = [ 1.52, 45, 15; 1.65, 68, 20; 1.68, 59, 18; 1.75, 68, 23];
03. VT = [H; F] ;
06. M = cov(VT);
07. [VP, Lambda] = eig (M)
08. [SortedLambda, indices] = sort(diag(Lambda), 'descend');
09. d = 1;
10. indices = indices(1:d);
11. W = VP(:, indices);
```

Et la sortie du programme :

```
VP =
0.9999628 0.0059912 0.0062125
-0.0080014 0.3737038 0.9275136
0.0032353 -0.9275287 0.3737378
```

Lambda =

2.0734e-03	0	0
0	3.8357e+00	0
0	0	2.0330e+02

1. De manière générale dans l'ACP quelle est la relation qui existe entre les valeurs propres calculées et la conservation de l'information ?
2. Expliquez à quoi sert la ligne 08. Pourquoi a-t-on besoin de cette étape ?
3. Expliquez ce que permettent de faire les instructions 09 à 11. Quelle est la valeur de W après l'exécution de ce code ?
4. Quel est le vecteur propre qui porte le moins d'information ? Comment est-il orienté dans l'espace (H, W, F) ? Comment sont orientés les deux autres vecteurs propres ? Si on projette les données en utilisant le vecteur W, tient-on réellement compte de l'information de taille (H) ?

On ajoute les lignes suivantes entre les lignes 03 et 06 :

04. VT = VT - mean (VT);  
05. VT = VT ./ sqrt(var(VT));

On obtient maintenant les résultats suivants :

VP =

-0.31119	-0.76428	0.56484
0.79718	0.11364	0.59295
-0.51737	0.63479	0.57390

Lambda =

0.051435	0	0
0	0.204870	0
0	0	2.743695

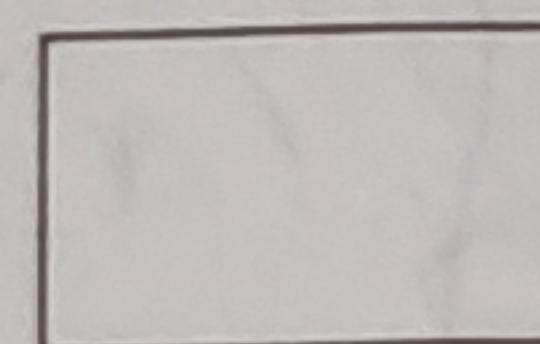
5. Expliquez à quoi servent les instructions ajoutées.
6. Quelle est maintenant la valeur de W ?
7. Pensez vous que cette nouvelle version permet de résoudre le problème pointé à la question 4 ? Justifiez.

FIN.

DE L'UE :  
JVE DE : ACD  
DE COURS :  
NONYMAT :

d'intercalaire(s) employé(s)

Groupe 5



Etudiant : Rabin X G  
A RABATTRE  
21609361  
Numéro de place

NOTE

APPRÉCIATIONS EXPLIQUANT LA NOTE CHIFFRÉE :

20  
- 20  
même pas!  
plus!

Ex1  $\frac{3}{8}$

Ex2 :  $\frac{6,5}{8}$

Ex3 :  $\frac{6}{6}$

### Exercice 1: Descente de gradient

1) a) Il intervient à la ligne  $x = x_{\text{current}} - \eta \alpha \times f'(x_{\text{current}})$ . Il nous permet d'aller dans le sens de la pente.

Si il est négatif, on "avance", sinon, on "recule".

b) La variable  $x_{\text{current}}$  contient la position du minimum à la fin de la fonction.

La valeur du minimum est alors  $f(x_{\text{current}})$ .

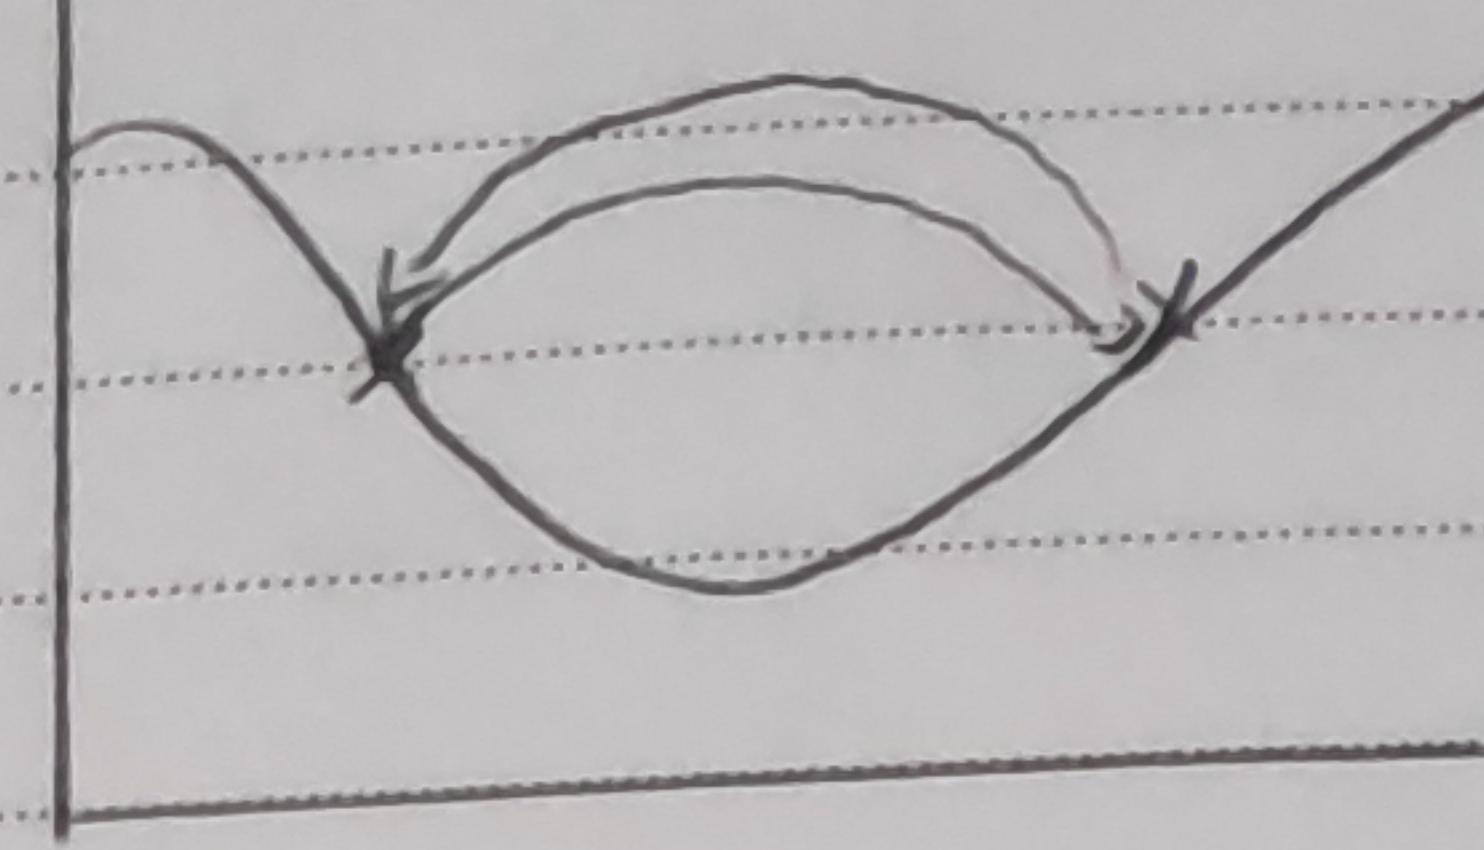
c) Il influence la longueur des "pas" que nous allons effectuer sur la courbe.

d) Le paramètre  $\eta$  influe sur la précision du résultat. Plus il est petit, plus le résultat sera précis et inversement.

e) Il permet de changer la longueur des pas que nous allons effectuer.

S'il est trop grand, on risque

de faire des aller-retours.



S'il est trop petit, on risque de mettre trop de temps à atteindre le minimum. ou de s'arrêter trop tôt.

Ex) a)  $f(x) = 3x^2 + 6x - 6$

b) securant:  $-\frac{1}{10} \rightarrow 0,557 \rightarrow 0,7297253$ ,  
 $\downarrow$   
 $0,727310184$

c) Si on choisit 4, on aura environ le même résultat. On arrive de l'autre côté du minimum.

Avec -4, nous n'avons pas le même résultat. En effet, nous allons suivre la pente, et donc on va aller vers la gauche de la courbe.

### Exercice n°2: Classification Bayésien

1) Avec le maximum de vraisemblance, on regarde la probabilité d'obtenir le feature  $x$  sachant que l'individu est d'une classe  $w$ .

Donc, si  $P(f=x | w_1) > P(f=x | w_2)$   
alors  $w_1$   
sinon  $w_2$

3

Avec le maximum a posteriori, on regarde la probabilité d'avoir une classe  $w$ , sachant que le feature est  $x$ .

Donc, si  $P(w_1 | f=x) > P(w_2 | f=x)$   
alors  $w_1$   
sinon  $w_2$

2) a)  $P(1) = \text{size 1} / (\text{size 1} + \text{size 2}) = 0,6$

0,5  $P(2) = 1 - P(1) = 0,4$

b) Le seuil est environ à 12,5

0,5 c) Pour MAP, on a :

$$P(w_1 | f=x) >? P(w_2 | f=x)$$

Alors nous avons la formule de Bayes :

$$P(1|B) = \frac{P(B|1) \times P(1)}{P(A)}$$

c) Notre classifieur MAP devient :

$$\frac{P(f=x | w_1) P(w_1)}{P(f=x)} >? \frac{P(f=x | w_2) P(w_2)}{P(f=x)}$$

Comme  $P(f=x)$  est partiel des deux côtés :

0,5  $P(f=x | w_1) P(w_1) >? P(f=x | w_2) P(w_2)$

On a donc le seuil de ML, mais déplacé avec les valeurs de  $P(w_1)$  et  $P(w_2)$ .

~~Donc pourtant correct et cela n'a pas d'importance~~

Comme  $P(w_1) > P(w_2)$ , on aura un NC seuil supérieur.

d)

3) a)  $P(1) = P(2) = 0,5$

0,5 b) Le seuil est environ à 10

0,5 c) Même explication que 2)c). Mais

comme  $P(1) = P(2)$ , le seuil reste le même,  $\approx 10$

d) L'erreur est  $\min(P(f=x | w_1), P(f=x | w_2))$

On peut donc faire l'erreur des résultats évaluation généralisable ?

### Exercice 3 : Réduction en dimension

1) La relation est: autant que la taille de la dimension cible.  
N,5 infestation cancéreux =  $\frac{T_1 + T_2}{\sum_{i=1}^n T_i}$

2) La ligne 8 sert à trier les valeurs propres.  
0,5 Cette ligne nous sert à sélectionner les axes d'inertie maximum.  
 On sélectionne donc la valeur propre la plus importante.

3) Les lignes 9 à 10 servent à sélectionner les vecteurs propres qui correspondent aux plus grandes valeurs propres.

2) Comme  $d=1$ , on prends la plus grande  $T_1$ , soit  $2,033 \approx 0,2$ , indice 3.  
0,5 On sélectionne donc la dernière ligne de VP, colonne

$$\text{donc } W = \begin{pmatrix} 0,0062125 \\ 0,9275136 \\ 0,3737378 \end{pmatrix}$$

4) C'est celui qui correspond à la plus petite valeur propre, soit la première colonne de VP.

1,5\* intercalaire un

5) 04 permet de recentrer la VT,  
05 permet de réduire, c'est-à-dire de faire en sorte que le nuage de point  $P$  ne soit plus influencé par les anomalies de mesure.

$$0,5 \quad 6) W = \begin{pmatrix} 0,56484 \\ 0,59235 \\ 0,57390 \end{pmatrix}$$

7) \* intercalaire

l'anonymat figurant sur la copie principale à reporter : ..... Rclin gragey

### Exo 3

4) suite : Comme la première ligne de ce  
est 0,0062125, on ne tient  
quasiment pas compte de la bâille. *on*

Le vecteur pince contenant le mains  
d'informations,  $\begin{pmatrix} 0,9999628 \\ -0,0080074 \\ 0,0032353 \end{pmatrix}$ ,

est uniquement orienté ~~par rapport~~ dans le  
"sens de la bâille"  $\rightarrow$  plus grand axe, on  
d'indice pour la bâille.

Le meilleur est orienté plus vers le poch,  
et le second meilleur plus vers foot siège.

7) Le problème est résolu, on ne dépendra  
plus de l'unité de mesure.

Le meilleur vecteur pince est

1  $\begin{pmatrix} 0,56484 \\ 0,59295 \\ 0,57390 \end{pmatrix}$ , à la projection tout  
TB est pris en compte avec ce  
vecteur